

Analyse de l'avantage à domicile dans le football (Premier League et Ligue 1 , saison 2017/18 à 2021/2022)

Raphaël ALCALA

1. Introduction

L'avantage à domicile est l'un des phénomènes les plus documentés dans le domaine de l'économie du sport. De manière empirique, les équipes jouant sur leur propre terrain obtiennent de meilleurs résultats que lorsqu'elles se déplacent. En Premier League (première division anglaise de football), ce taux de victoire à domicile s'établit historiquement autour de 45%, contre environ 28% pour les équipes extérieures. Cet avantage est généralement attribué à plusieurs facteurs : le soutien du public, la familiarité avec le terrain, l'absence de fatigue liée aux déplacements, ou encore la pression psychologique exercée sur l'arbitre.

Cependant, identifier précisément la contribution de chacun de ces facteurs reste difficile, car ils coexistent dans des conditions normales de compétition. La pandémie de Covid-19 a offert une opportunité unique de les dissocier. Entre mars 2020 et mai 2021, les ligues professionnelles européennes ont été contraintes de disputer leurs matchs à huis clos, supprimant ainsi la présence du public. Cette situation constitue une opportunité permettant d'isoler l'effet du public sur l'avantage à domicile.

Ce projet vise à quantifier les déterminants de la victoire à domicile en Premier League anglaise et en Ligue 1 française sur cinq saisons (2017/2018 à 2021/2022), en couvrant à la fois des saisons avec public et des saisons à huis clos. Nous estimons un modèle logit dont la variable dépendante est binaire : victoire de l'équipe à domicile (1) ou non (0). Les variables explicatives retenues sont la présence du public (variable Covid), la forme récente des deux équipes mesurée sur les cinq derniers matchs, et l'écart de points au classement pour montrer le niveau relatif des équipes.

Nous avons choisi de prendre deux championnats différents , la Premier League et la Ligue 1 afin d'élargir nos résultats et pouvoir les comparer entre eux. Ce choix vient également se justifier au vu du dernier projet réalisé "Les déterminants de la valeur marchande en Liga", qui portait uniquement sur une seule ligue et qui a montré ses limites.

Ce projet est organisé comme suit : la section 2 présente les données utilisées et la construction des variables. La section 3 expose la méthodologie économétrique et justifie le choix du modèle logit. Les sections 4 et 5 présentent les résultats pour la Premier League et la Ligue 1 respectivement. La section 6 propose une comparaison directe entre les deux championnats. La section 7 conclut et discute les limites du projet.

2. Données et construction des variables

2.1 Sources

Les données de Premier League sont issues d'un dataset Kaggle couvrant l'ensemble des matchs disputés de 1993 à 2024. Ce dataset inclut pour chaque rencontre le score, le résultat, ainsi que des statistiques de jeu détaillées (tirs, corners, cartons). Les données de Ligue 1 ont quant à elles été collectées sur le site football-data.co.uk, qui met à disposition les résultats historiques de toutes les grandes ligues européennes sous forme de fichiers CSV.

Cinq fichiers CSV distincts ont été fusionnés pour reconstituer l'historique complet de la Ligue 1 sur les saisons retenues. Un soin particulier a été apporté à l'harmonisation des formats de date entre les fichiers, les conventions d'écriture variant selon les saisons. Au total, nous disposons de 1 848 matchs pour la Premier League et de 1 799 matchs pour la Ligue 1, répartis sur cinq saisons de 2017/2018 à 2021/2022.

2.2 Échantillon

Le tableau suivant résume la répartition des matchs par saison et par championnat. On notera que la saison 2019-2020 de Ligue 1 compte que 279 matchs au lieu de 380, la compétition ayant été définitivement arrêtée en mars 2020 en raison de la pandémie. La Premier League, à l'inverse, a repris en juin 2020 à huis clos et a pu aller à son terme.

Saison	Premier League	Ligue 1	Total
2017-2018	380	380	760
2018-2019	380	380	760
2019-2020	380	279 (arrêtée)	659
2020-2021	380	380	760
2021-2022	380	380	760
Total	1 900	1 799	3 699

2.3 Variable dépendante

La variable dépendante est `home_win`, une variable binaire prenant la valeur 1 si l'équipe à domicile remporte le match et 0 dans le cas contraire (nul ou victoire de l'équipe extérieure).

Les matchs nuls ne sont donc pas traités séparément mais regroupés avec les défaites à domicile, ce qui est cohérent avec notre objectif : mesurer la probabilité de victoire de l'équipe recevant. Sur l'ensemble de la période, le taux de victoire à domicile s'établit à 43,8% en Premier League et à 43,1% en Ligue 1. Ces taux sont sensiblement inférieurs lors des saisons à huis clos : 40,3% et 36,8% respectivement, ce qui constitue déjà un premier indice de l'effet du public sur le résultat.

2.4 Variables explicatives

Quatre variables explicatives ont été construites à partir des données brutes. Chacune a fait l'objet d'un traitement spécifique pour garantir qu'elle reflète l'information disponible avant le coup d'envoi du match.

Variable	Description	Construction
covid	Huis clos (1 = sans public, 0 = avec public)	Saison 2020-21 complète + PL à partir de mars 2020
home_form	Forme récente de l'équipe à domicile	Moyenne de points sur les 5 derniers matchs (décalée d'1)
away_form	Forme récente de l'équipe extérieure	Moyenne de points sur les 5 derniers matchs (décalée d'1)
ranking_diff	Écart de niveau entre les équipes	Points cumulés domicile – points cumulés extérieur (avant le match)

2.5 Statistiques descriptives

Le tableau ci-dessous présente les statistiques descriptives des variables numériques pour les deux championnats. On constate que la forme récente moyenne est légèrement supérieure à 1,3 point par match, ce qui est cohérent avec une distribution des résultats partagée entre victoires, nuls et défaites. L'écart au classement (ranking_diff) présente une distribution centrée autour de zéro avec une dispersion importante, reflétant la variété des oppositions au cours d'une saison.

Variable	Moyenne PL	Écart-type PL	Moyenne L1	Écart-type L1
home_win	0.438	0.496	0.431	0.495
covid	0.253	0.435	0.218	0.413
home_form	1.368	0.694	1.341	0.682
away_form	1.401	0.702	1.378	0.695
ranking_diff	0.21	15.3	0.18	14.7

Tableau 1 — Statistiques descriptives des variables pour la Premier League et la Ligue 1.

3. Méthodologie

3.1 Choix du modèle logit

La variable dépendante home_win est binaire : elle prend la valeur 1 si l'équipe à domicile remporte le match, et 0 dans le cas contraire. Ceci impose des contraintes sur le choix du modèle économétrique. L'utilisation d'une régression linéaire par les moindres carrés ordinaires (MCO) serait inappropriée pour deux raisons principales.

D'une part, un modèle linéaire peut produire des valeurs prédites en dehors de l'intervalle [0, 1], ce qui est incohérent pour une probabilité. D'autre part, l'hypothèse d'homoscédasticité des erreurs est systématiquement violée lorsque la variable dépendante est binaire, ce qui rend les tests statistiques non fiables.

Le modèle logit résout ces deux problèmes en modélisant directement le logarithme du rapport de cotes (log-odds) de la victoire à domicile comme une fonction linéaire des variables explicatives. La probabilité prédite est ensuite obtenue par la fonction logistique, qui garantit des valeurs comprises entre 0 et 1 :

$$P(\text{home_win} = 1) = 1 / (1 + \exp(-(b_0 + b_1 \cdot \text{covid} + b_2 \cdot \text{home_form} + b_3 \cdot \text{away_form} + b_4 \cdot \text{ranking_diff})))$$

3.2 Interprétation des effets marginaux

Dans un modèle logit, les coefficients estimés (β_k) ne s'interprètent pas directement comme des variations de probabilité. Ils représentent l'effet d'une augmentation d'une unité de la variable explicative sur le log-odds de la victoire, ce qui n'est pas intuitif économiquement.

Pour faciliter l'interprétation, on calcule les effets marginaux (dy/dx), qui mesurent la variation de la probabilité de victoire à domicile associée à une augmentation d'une unité de chaque variable explicative, les autres variables étant maintenues à leur valeur moyenne. Ces effets sont exprimés en points de pourcentage et constituent la grandeur commentée dans les sections de résultats.

Formellement, l'effet marginal de la variable X_k s'écrit :

$$dP/dX_k = \beta_k * P * (1 - P)$$

où P est la probabilité prédite évaluée à la valeur moyenne de toutes les variables. On remarque que cet effet dépend du niveau de P , ce qui signifie que l'effet marginal n'est pas constant mais varie selon le contexte du match.

3.3 Hypothèses et variables de contrôle

Notre modèle repose sur plusieurs hypothèses. Premièrement, nous supposons que l'effet du huis clos est homogène, c'est-à-dire identique pour toutes les équipes. Cette hypothèse est une simplification : certains clubs, notamment ceux bénéficiant d'un public particulièrement hostile pour les adversaires, pourraient être plus affectés que d'autres par l'absence de supporters.

Deuxièmement, nous contrôlons le niveau relatif des équipes via la variable `ranking_diff`. Ce choix est préférable à l'utilisation du classement absolu car il capture directement l'écart de qualité entre les deux équipes en présence, indépendamment de leur position générale dans la hiérarchie du championnat.


Troisièmement, la forme récente est calculée sur une fenêtre glissante de cinq matchs. Ce choix résulte d'un mélange entre la réactivité aux performances récentes et la robustesse statistique. Une fenêtre trop courte serait trop sensible aux résultats ponctuels, tandis qu'une fenêtre trop longue diluerait l'effet de la dynamique récente.

4. Résultats: Premier League

4.1 Aperçu descriptif

Sur les cinq saisons étudiées, le taux de victoire à domicile en Premier League s'établit à 43,8% en moyenne. Ce chiffre cache des variations importantes selon les saisons. Les deux saisons pré-Covid (2017-2018 et 2018-2019) affichent des taux élevés, respectivement 45,7% et 47,8%, témoignant d'un avantage à domicile fort. La saison 2019-2020 présente un taux intermédiaire de 45,4%, la première partie s'étant déroulée normalement avant l'interruption due à la pandémie.

La saison 2020-2021, disputée entièrement à huis clos, enregistre la chute la plus marquée avec seulement 38% de victoires à domicile, soit une baisse de près de 8 points par rapport à la saison précédente. Ce seul constat descriptif constitue déjà un signal fort en faveur d'un effet du public. La saison 2021-2022, avec le retour progressif des supporters, affiche un rebond à 42,2%, encore légèrement en dessous de la moyenne historique, ce qui pourrait s'expliquer par un retour du public incomplet en début de saison.



4.2 Résultats du modèle logit

Le modèle logit est estimé sur 1 848 observations après suppression des valeurs manquantes liées au calcul de la forme récente en début de saison. Le modèle converge en 5 itérations et présente un R^2 de 0,079. Le test du rapport de vraisemblance est hautement significatif : $LLR\ p\text{-value} = 4,47 \times 10^{-42}$,

confirmant que le modèle apporte une information statistiquement significative par rapport à un modèle sans variable explicative

Variable	Coef.	Std. err.	z	p-value	Effet marginal
Constante	-0.158	0.138	-1.149	0.250	—
Covid (huis clos)	-0.228	0.114	-1.992	0.046	-5.0 pp *
Forme domicile	+0.210	0.077	+2.743	0.006	+4.7 pp **
Forme extérieur	-0.243	0.078	-3.136	0.002	-5.4 pp **
Écart classement	+0.034	0.004	+7.772	<0.001	+0.76 pp ***

Tableau 2 — Résultats du modèle logit et effets marginaux — Premier League. pp = points de pourcentage. * seuil 5%, ** seuil 1%, *** seuil 0,1%.

4.3 Interprétation variable par variable

-Écart au classement: C'est le déterminant le plus robuste et le plus significatif du modèle ($z = 7,77$, $p < 0,001$). Son effet marginal de +0,76 point de pourcentage signifie que chaque point d'écart supplémentaire au classement en faveur de l'équipe à domicile augmente sa probabilité de victoire de 0,76 points de pourcentage. Ce résultat est cohérent avec l'intuition économique : la qualité relative des équipes est la principale raison du résultat d'un match, indépendamment du contexte dans lequel il se joue.

-Forme récente des deux équipes: La forme de l'équipe à domicile est significative au seuil de 1% ($p = 0,006$) avec un effet marginal de +4,7 pp par point de forme supplémentaire. La forme de l'équipe extérieure est également significative au seuil de 1% ($p = 0,002$) avec un effet négatif de -5,4 points de pourcentage. Ces résultats montrent que la dynamique de confiance et la condition physique des équipes jouent un rôle réel en Premier League. Une équipe à domicile en pleine confiance face à un adversaire en méforme constitue une combinaison particulièrement favorable pour l'équipe recevante.

-Effet Covid (huis clos): La variable covid est significative au seuil de 5% ($z = -1,992$, $p = 0,046$). Son effet marginal de -5,0 points de pourcentage signifie que l'absence de public réduit en moyenne la probabilité de victoire à domicile de 5 points de pourcentage. Il est important de souligner que cet effet est estimé en contrôlant simultanément le niveau des équipes et leur forme récente : ce n'est donc pas un simple effet de composition, mais bien l'effet propre de l'absence de public sur le résultat.

4.4 Analyse graphique des résultats

2. Probabilité prédite selon l'écart au classement




Figure 2: Probabilité prédite de victoire à domicile en Premier League selon l'écart au classement, avec et sans public. Les autres variables sont maintenues à leur valeur moyenne.

La figure 2 illustre graphiquement l'effet du huis clos à travers la courbe logistique. On représente la probabilité prédite de victoire à domicile en fonction de l'écart au classement pour deux conditions : avec public (courbe verte pleine) et sans public (courbe rouge pointillée). Les autres variables, forme domicile et forme extérieur, sont maintenues à leur valeur moyenne respective.

Plusieurs enseignements ressortent de ce graphique. D'abord, la relation entre écart au classement et probabilité de victoire est réelle : elle est plus pentue autour de zéro et s'aplatit aux extrêmes, ce qui est cohérent avec la réalité sportive, un écart de classement supplémentaire change plus le résultat quand les équipes sont proches que quand elles sont très éloignées en niveau. Ensuite, l'écart entre les deux courbes, d'environ 5 points de pourcentage, est visible et constant sur toute la plage de valeurs. Que l'équipe à domicile soit favorite ou outsider, jouer à huis clos réduit systématiquement ses chances de victoire. Ce résultat confirme la robustesse de l'effet estimé et montre qu'il ne dépend pas du contexte du match.

3. Forme domicile selon le résultat




Figure 3: Distribution de la forme récente de l'équipe à domicile selon le résultat du match en Premier League.

La figure 3 représente la distribution de la forme récente de l'équipe à domicile pour deux groupes : les matchs remportés par l'équipe domicile (vert) et les matchs perdus ou nuls (orange).

Premièrement, les distributions des deux groupes se chevauchent largement, ce qui est attendu : la forme récente seule ne suffit pas à prédire le résultat d'un match.

Deuxièmement, la distribution des victoires est décalée vers la droite par rapport à celle des défaites et nuls : les équipes victorieuses à domicile avaient en moyenne une meilleure forme récente. Ce décalage, bien que modeste visuellement, est statistiquement significatif ($p = 0,006$ dans le modèle). Troisièmement, on observe que les équipes en très mauvaise forme (forme ≈ 0 , soit aucun point sur les 5 derniers matchs) sont surreprésentées dans le groupe des équipes n'ayant pas gagné, ce qui confirme que la méforme est pénalisante même à domicile.




Figure 4: Forme récente de l'équipe à domicile selon le résultat du match et la présence ou non du public en Premier League.

La figure 4 apporte un éclairage complémentaire en croisant deux dimensions : le résultat du match (victoire vs défaite/nul) et la condition de jeu (huis clos vs public présent). Chaque boîte à moustaches représente la distribution de la forme récente de l'équipe à domicile pour une combinaison de ces deux facteurs.

Plusieurs constats s'imposent. D'abord, dans les deux conditions (huis clos et public présent), les équipes victorieuses présentent une forme récente médiane plus élevée que les équipes n'ayant pas gagné, confirmant la relation positive entre forme et résultat observée dans le modèle. Ensuite, et c'est le résultat le plus intéressant de ce graphique, les distributions de forme sont très similaires entre matchs à huis clos et matchs avec public, aussi bien pour les victoires que pour les défaites. Cela signifie que la forme récente des équipes n'était pas différente pendant le Covid par rapport aux autres saisons, ce qui valide notre modélisation : la baisse de victoires domicile pendant le Covid ne s'explique pas par une différence de niveau ou de forme des équipes, mais bien par l'absence du public elle-même.

5. Résultats: Ligue 1

5.1 Spécificités de la Ligue 1

La Ligue 1 présente une particularité importante qui la distingue de la Premier League dans notre analyse. Suite à la pandémie de Covid-19 et à la décision du gouvernement français d'interdire les rassemblements publics, la saison 2019-2020 a été définitivement arrêtée en mars 2020 après seulement 279 matchs disputés sur 380. Contrairement à la Premier League qui a repris à huis clos en juin 2020, la Ligue 1 a choisi de ne pas terminer sa saison. La saison 2019-2020 n'est donc pas une saison à huis clos dans notre modèle, elle est simplement incomplète avec public. Seule la saison 2020-2021, disputée intégralement sans supporters, constitue notre période de référence pour l'effet Covid en Ligue 1.

5.2 Aperçu descriptif

Le taux de victoire à domicile moyen sur les cinq saisons est de 43,1% en Ligue 1, très proche de celui observé en Premier League (43,8%). Cependant, les variations saisonnières sont plus marquées. La saison 2019-2020, avec un taux de 48,3%, affiche le taux le plus élevé de la période, un résultat à interpréter avec prudence compte tenu du faible nombre de matchs disputés (279) et d'un possible biais de sélection si les matchs non joués avaient des caractéristiques particulières.

La chute pendant le huis clos est spectaculaire : 36,8% en 2020-2021, soit la valeur la plus basse des cinq saisons et un recul de 7,9 points par rapport à la moyenne des quatre autres saisons. Ce constat est encore plus frappant qu'en Premier League où la chute était de 5,8 points. La saison 2021-2022, avec le retour du public, affiche un rebond à 43,8%, quasiment identique à la moyenne historique, suggérant une récupération plus rapide et complète de l'avantage à domicile qu'en Premier League.




Figure 5: Taux de victoire à domicile par saison en Ligue 1 (2017-2022). La ligne pointillée représente la moyenne sur les 5 saisons (43,1%). La chute de 2020-2021 est plus prononcée qu'en Premier League.

5.3 Résultats du modèle logit

Le modèle logit est estimé sur 1 746 observations. Il converge en 5 itérations avec un pseudo R^2 de 0,064, inférieur à celui obtenu pour la Premier League (0,079). Le test du rapport de vraisemblance reste néanmoins très significatif: $LLR\ p\text{-value} = 5,80 \times 10^{-32}$ confirmant la pertinence globale du modèle.

Variable	Coef.	Std. err.	z	p-value	Effet marginal
Constante	-0.288	0.147	-1.965	0.049	—
Covid (huis clos)	-0.379	0.127	-2.994	0.003	-8.5 pp **
Forme domicile	+0.128	0.082	+1.561	0.119	+2.9 pp NS
Forme extérieur	-0.070	0.079	-0.883	0.378	-1.6 pp NS
Écart classement	+0.044	0.005	+8.057	<0.001	+0.98 pp ***

Tableau 3: Résultats du modèle logit et effets marginaux, Ligue 1. pp = points de pourcentage. NS = non significatif, ** seuil 1%, *** seuil 0,1%.

5.4 Interprétation variable par variable

-Écart au classement.: Comme en Premier League, l'écart au classement est le déterminant le plus robuste ($z = 8,057$, $p < 0,001$). Son effet marginal de +0,98 pp est légèrement supérieur à celui observé en Premier League (+0,76 pp), ce qui pourrait refléter une hiérarchie plus prononcée entre les clubs en Ligue 1, où les écarts de niveau entre le haut et le bas du classement sont parfois plus marqués.

-Effet Covid (huis clos): C'est sans conteste le résultat le plus marquant du modèle Ligue 1. Avec un coefficient de -0,379 et une p-value de 0,003, l'effet est significatif au seuil de 1% et se traduit par un effet marginal de -8,5 points de pourcentage. Ce chiffre est considérablement plus élevé qu'en Premier League (-5,0 pp), ce qui suggère que l'absence de public affecte davantage l'avantage à domicile en France qu'en Angleterre.

-Forme récente: Contrairement à la Premier League, ni la forme de l'équipe à domicile ($p = 0,119$) ni celle de l'équipe extérieure ($p = 0,378$) ne sont statistiquement significatives en Ligue 1. Ce résultat est notable : il suggère que la dynamique de confiance est moins prédictive du résultat en France qu'en Angleterre. Cela pourrait s'expliquer par une plus grande irrégularité des performances en Ligue 1, rendant les résultats des derniers matchs moins informatifs sur la probabilité de victoire du prochain.

5.5 Analyse graphique des résultats

2. Probabilité prédite selon l'écart au classement




Figure 6: Probabilité prédite de victoire à domicile en Ligue 1 selon l'écart au classement, avec et sans public. Les autres variables sont maintenues à leur valeur moyenn

La figure 6 illustre graphiquement l'effet du huis clos en Ligue 1 à travers la courbe logistique. Comme en Premier League, on représente la probabilité prédite de victoire à domicile en fonction de l'écart au classement pour deux conditions : avec public (courbe verte) et sans public (courbe rouge pointillée).

L'écart entre les deux courbes est visuellement plus prononcé qu'en Premier League, ce qui est cohérent avec l'effet marginal plus fort estimé (-8,5 pp vs -5,0 pp). Pour un match entre deux équipes de niveau équivalent (écart au classement = 0), la probabilité de victoire domicile passe d'environ 43% avec public à environ 35% sans public, soit une chute de 8 points. Ce graphique constitue une représentation du principal résultat du projet : le public est un facteur d'avantage à domicile plus déterminant en Ligue 1 qu'en Premier League.




Figure 7: Distribution de la forme récente de l'équipe à domicile selon le résultat du match en Ligue 1.

La figure 7 représente la distribution de la forme récente de l'équipe à domicile selon que le match a été remporté (vert) ou non (orange). En Ligue 1, le décalage entre les deux distributions est moins net qu'en Premier League, ce qui est cohérent avec la non-significativité de la variable forme domicile dans le modèle ($p = 0,119$).

Les deux distributions se chevauchent largement, et les pics de densité sont proches pour les deux groupes autour d'une forme de 1 point par match. On observe tout de même que les équipes victorieuses sont légèrement surreprésentées pour des valeurs de forme élevées (au-delà de 1,5 point), mais cet écart reste insuffisant pour être statistiquement significatif sur l'ensemble de l'échantillon. Ce résultat confirme qu'en Ligue 1, la forme récente est un indicateur moins fiable du résultat suivant qu'en Premier League.




Figure 8: Forme récente de l'équipe à domicile selon le résultat du match et la présence ou non du public en Ligue 1.

La figure 8 croise le résultat du match avec la condition de jeu (huis clos vs public présent) pour analyser la forme récente de l'équipe à domicile. Comme en Premier League, les distributions de forme sont très similaires entre matchs à huis clos et matchs avec public, aussi bien pour les victoires que pour les défaites et nuls.

Ce résultat est particulièrement important pour valider notre approche économétrique. Il confirme que les équipes n'étaient pas structurellement moins en forme pendant la saison à huis clos, les médianes et les distributions sont quasiment identiques entre les deux conditions. La baisse du taux de victoire domicile pendant le Covid ne peut donc pas être attribuée à une différence de niveau ou de forme des équipes cette saison-là : elle s'explique bien par l'absence du public elle-même, et non par un facteur confondant lié à la qualité des équipes en présence. Ce graphique apporte ainsi une validation visuelle de la pertinence de notre variable covid dans le modèle.

6. Comparaison Premier League / Ligue 1

Les deux modèles estimés permettent une comparaison directe des déterminants de l'avantage à domicile entre la Premier League et la Ligue 1. Au-delà des résultats individuels présentés dans les sections précédentes, cette mise en regard révèle des similitudes structurelles mais aussi des différences notables qui éclairent les spécificités de chaque championnat.

	Premier League	Ligue 1
Observations	1 848	1 746
Pseudo R ²	0.079	0.064
Taux victoire domicile (global)	43.8%	43.1%
Taux sans Covid (avec public)	45.1%	44.7%
Taux avec Covid (huis clos)	40.3%	36.8%
Baisse due au huis clos	-4.8 pp	-7.9 pp
Effet Covid — modèle	-5.0 pp * (p=0.046)	-8.5 pp ** (p=0.003)
Forme domicile	+4.7 pp ** (p=0.006)	+2.9 pp NS (p=0.119)
Forme extérieur	-5.4 pp ** (p=0.002)	-1.6 pp NS (p=0.378)
Écart classement	+0.76 pp *** (p<0.001)	+0.98 pp *** (p<0.001)

Tableau 4: Comparaison des résultats entre Premier League et Ligue 1. NS = non significatif · * seuil 5% · ** seuil 1% · *** seuil 0,1% · pp = points de pourcentage.

6.1 Un effet Covid structurellement plus fort en Ligue 1

Le résultat le plus frappant de cette comparaison est l'ampleur différente de l'effet du huis clos selon le championnat. En Ligue 1, l'absence de public réduit la probabilité de victoire domicile de 8,5 points de pourcentage dans le modèle, contre 5 points en Premier League. Cet écart de 3,5 points est économiquement significatif et robuste : il se retrouve également dans les statistiques descriptives brutes, avec une baisse observée de 7,9 points en Ligue 1 contre 4,8 points en Premier League.

6.2 La forme récente : un facteur distinctif entre les deux ligues

La forme récente constitue la deuxième grande différence entre les deux championnats. En Premier League, les deux variables de forme sont significatives au seuil de 1%, avec des effets marginaux substantiels (+4,7 pp pour la forme domicile, -5,4 pp pour la forme extérieure). En Ligue 1, aucune des deux n'est significative, avec des p-values de 0,119 et 0,378 respectivement.

6.3 L'écart au classement : un facteur universel

Dans les deux championnats, l'écart au classement est le déterminant le plus robuste et le plus significatif, avec des p-values inférieures à 0,001. Son effet est légèrement plus élevé en Ligue 1 (+0,98 pp) qu'en Premier League (+0,76 pp). Ce résultat est le seul qui soit parfaitement cohérent entre les deux modèles et confirme une vérité fondamentale du football : la qualité relative des équipes prime sur tous les autres facteurs pour expliquer le résultat d'un match. L'effet légèrement plus fort en Ligue 1 pourrait s'expliquer par une hiérarchie plus nette entre les clubs français. Contrairement à la Premier League où six à huit équipes peuvent prétendre au titre ou à l'Europe chaque saison, la Ligue 1 est souvent dominée par un nombre plus restreint de clubs, créant des écarts de niveau plus prononcés entre le haut et le bas du classement.

6.4 Synthèse

Au total, les deux modèles convergent sur un point essentiel : l'avantage à domicile existe, il est mesurable, et une partie s'explique par la présence du public. Mais l'ampleur de cet effet du public diffère selon le championnat, ce qui suggère que l'avantage à domicile n'est pas un phénomène universel et homogène, mais bien un phénomène contextuellement ancré, façonné par les spécificités culturelles, économiques et structurelles de chaque ligue.

7. Limites et conclusion

7.1 Limites Plusieurs limites doivent être soulevées pour nuancer les résultats obtenus et identifier les pistes d'amélioration futures.

La première limite concerne la mesure de l'effet Covid. Notre variable covid est binaire et traite le huis clos comme un phénomène homogène, alors que la réalité a été plus nuancée : certains matchs se sont joués avec des jauges partielles de 1 000, 5 000 ou 25% de la capacité du stade, selon les périodes et les décisions des autorités sanitaires. Ne pas distinguer ces situations introduit une imprécision dans l'estimation de l'effet du public et conduit probablement à le sous-estimer, dans la mesure où certains matchs codés comme 'avec public' se sont en réalité joués devant des tribunes partiellement vides.

La deuxième limite tient au pouvoir explicatif du modèle. Le pseudo R^2 reste modeste: 0,079 pour la Premier League et 0,064 pour la Ligue 1, ce qui reflète la part irréductible d'aléa dans le résultat d'un match de football. Des variables importantes n'ont pas pu être intégrées faute de données disponibles ou compatibles : les expected goals (xG) qui mesurent la qualité des occasions créées indépendamment du score, la distance parcourue par l'équipe extérieure avant le match comme proxy de la fatigue liée aux déplacements, ou encore l'enjeu du match en fin de saison (lutte pour le titre, qualification européenne, relégation) qui peut modifier profondément la motivation des équipes.

La troisième limite porte sur l'hypothèse d'homogénéité de l'effet domicile. Notre modèle suppose que l'avantage à domicile s'applique de manière identique à toutes les équipes, ce qui est une simplification réductrice. En réalité, certains clubs bénéficient d'un avantage à domicile structurellement plus fort, notamment ceux dont le stade est particulièrement intimidant, dont le public est réputé pour sa pression sur les arbitres, ou dont les joueurs sont très attachés à leur enceinte. Un modèle à effets fixes équipe permettrait de contrôler ces hétérogénéités non observées et d'obtenir des estimations plus précises de l'effet moyen du huis clos.

Enfin, en Ligue 1, la saison 2020-2021 constitue la seule période de huis clos complet, ce qui limite la robustesse de l'estimation de l'effet Covid pour ce championnat. Une variation plus étendue dans le temps, par exemple en couvrant plusieurs championnats européens sur la même période, permettrait d'obtenir des estimations plus fiables et de tester la généralité des résultats obtenus.

7.2 Conclusion

Ce projet confirme l'existence d'un avantage à domicile significatif en Premier League et en Ligue 1 sur la période 2017-2022, et montre que cet avantage est partiellement expliqué par la présence du public. La pandémie de Covid-19, en supprimant les supporters des tribunes pendant une saison entière, a fourni une quasi-expérience naturelle permettant d'isoler et de quantifier cet effet de manière causale, en contrôlant simultanément le niveau relatif des équipes et leur forme récente.

Les résultats du modèle logit montrent que le huis clos réduit la probabilité de victoire à domicile de 5 points de pourcentage en Premier League et de 8,5 points en Ligue 1. Cette différence entre les deux championnats constitue l'un des résultats les plus intéressants du projet et invite à ne pas considérer l'avantage à domicile comme un phénomène universel et homogène : il est ancré dans des spécificités culturelles, économiques et structurelles propres à chaque ligue.

Le facteur le plus déterminant reste dans les deux cas l'écart au classement, qui reflète la qualité relative des équipes. Ce résultat est cohérent avec la littérature économétrique sur le sujet et rappelle que l'avantage à domicile, aussi réel soit-il, ne suffit pas à compenser un écart de niveau important entre les deux équipes en présence. La forme récente, en revanche, se révèle être un déterminant significatif en Premier League mais pas en Ligue 1.

Plusieurs pistes d'approfondissement peuvent être envisagées. Étendre l'analyse à d'autres championnats européens, Bundesliga, Serie A, Liga, permettrait de tester la robustesse des résultats et d'identifier si l'effet du public varie systématiquement selon les cultures footballistiques nationales. L'intégration de données xG améliorerait le contrôle de la qualité de jeu et réduirait le biais dû aux variables omises. Enfin, l'utilisation d'un modèle à effets fixes équipe permettrait de mieux contrôler les caractéristiques non observées propres à chaque club et d'obtenir une estimation plus précise et plus robuste de l'effet causal du public sur le résultat d'un match.

Données : Kaggle (Premier League) · football-data.co.uk (Ligue 1) · Outils : Python 3.12 (pandas, statsmodels, matplotlib) · R 4.5 (ggplot2, dplyr)